

无病灶标注条件下腹膜后肿瘤 CT 二分类筛查模型的初步研究

J. Ho Codex 协作整理

2026 年 7 月

摘要

目的：在缺乏医生逐层肿瘤 ROI 标注的现实条件下，构建一个可复现、低成本的腹膜后肿瘤 CT 二分类筛查模型，用于区分“良性神经源性肿瘤”和“非良性/需处理病变”。方法：本研究整理 246 例腹膜后肿瘤增强 CT 病例，其中良性神经源性肿瘤 55 例，非良性/需处理病变 191 例，后者包括肉瘤类、淋巴瘤、嗜铬细胞瘤/副神经节瘤和胃肠道间质瘤。模型不使用分割掩膜或肿瘤中心点，而是将每例 CT 表示为 96 张轴位切片；每张切片经三种 CT 窗动态转换为三通道图像，并由 ImageNet 预训练 ResNet18 提取切片特征。随后使用基于 mean/max pooling 的 2.5D 弱监督多实例学习框架进行病例级分类，并融合年龄、性别等表格特征。评价采用患者级五折交叉验证，重点关注非良性/需处理病变被误判为良性的假阴性风险。结果：主模型在合并五折测试集上取得 Accuracy 0.821、Balanced Accuracy 0.691、Macro-F1 0.711、Sensitivity 0.927、Specificity 0.455、AUROC 0.670、Average Precision 0.848。混淆矩阵显示 191 例非良性/需处理病例中 177 例被正确识别，假阴性 14 例；55 例良性神经源性肿瘤中 25 例被正确识别，30 例被判为非良性/需处理。结论：在无 ROI 标注条件下，2.5D 弱监督 MIL 结合年龄/性别特征可以形成一个可运行的腹膜后肿瘤筛查式二分类基线。当前模型更适合作为“尽量不漏掉需处理病变”的初步筛查工具，而不能作为临床诊断模型。

关键词：腹膜后肿瘤；CT；弱监督学习；多实例学习；ResNet18；二分类筛查

1 引言

腹膜后肿瘤病理类型复杂，影像表现具有一定重叠性。在正式临床诊断中，病理学结论仍是金标准；影像模型若要达到临床可用水平，通常需要更大的样本、多中心外部验证，以及由医生标注的肿瘤区域。然而在当前数据条件下，逐层分割 ROI 的成本过高，且已有数据主要是病例级诊断标签。因此，本研究没有复刻基于病灶分割的分类路线，而是将问题重新定义为一个更务实的弱监督筛查任务。

本研究的主任务不是严格病理学意义上的“良恶性分类”，而是：

良性神经源性肿瘤 vs 非良性/需处理腹膜后病变。

这一设定的临床含义更接近“哪些病例不能简单视作普通良性神经源性肿瘤”。其中嗜铬细胞瘤/副神经节瘤（PPGL）并不被简单称为恶性，但其临床处理方式、术前评估和风险管理均不同于普通良性神经源性肿瘤，因此被归入“非良性/需处理病变”。

2 材料与amp;方法

2.1 数据集与amp;标签定义

本研究共纳入 246 例可用增强 CT 病例。标签由既有病例表格整理得到，最终固定为二分类任务。类别构成见表1。

表 1: 二分类标签构成

二分类标签	纳入原始类别	例数
良性神经源性肿瘤	良性神经源性肿瘤	55
非良性/需处理病变	肉瘤类	103
	淋巴瘤	44
	PPGL	30
	胃肠道间质瘤	14
合计		246

所有训练、验证和测试划分均按患者级别进行，避免同一患者不同序列或派生样本跨集合造成数据泄漏。实验采用五折交叉验证，并将每折测试结果合并后计算总体指标。

2.2 影像预处理

每例 CT 以 NIfTI 格式读取。模型输入不依赖人工肿瘤框、分割掩膜或点击点，而是直接使用整套 CT。预处理流程如下：

- 沿轴位方向从每例 CT 中采样 96 张切片。
- 每张切片 resize 至 224×224 。
- 将 HU 值转换为三通道 CT 窗图像：
 - 软组织窗： $[-160, 240]$ ；
 - 脂肪敏感窗： $[-200, 100]$ ；
 - 宽腹部窗： $[-200, 400]$ 。
- 每个窗内线性归一化到 $[0, 1]$ ，随后使用 ImageNet 均值和标准差进行标准化，以适配预训练 ResNet18。

三窗设置的动机是尽量同时保留软组织密度、脂肪成分和较宽范围腹部结构信息。对于脂肪肉瘤等病变，脂肪成分具有潜在诊断价值；对于淋巴瘤、PPGL 和其他实体肿瘤，软组织窗和宽窗则可能提供更稳定的密度与解剖背景。

2.3 模型结构

模型采用 2.5D 弱监督多实例学习（multiple instance learning, MIL）框架。每例 CT 被视为一个 bag，96 张轴位切片为 instances。整体结构如图1所示，并可形式化为：

$$x = \{x_1, x_2, \dots, x_{96}\}, \quad f_i = \text{ResNet18}(x_i), \quad f_i \in \mathbb{R}^{512}$$

其中 ResNet18 使用 ImageNet 预训练权重，并作为切片级特征提取器。每例 CT 的影像特征由切片特征的 mean pooling 和 max pooling 组合得到：

$$h_{\text{img}} = [\text{mean}(f_1, \dots, f_{96}); \text{max}(f_1, \dots, f_{96})]$$

表格特征包括年龄与性别。主模型使用影像分支和表格分支的晚期融合：影像分支输出病例级非良性/需处理概率，表格分支输出基于年龄/性别的概率，最终以等权方式得到融合预测。该设计有三个优点：一是代码较简洁；二是可以直接检查影像分支和表格分支各自贡献；三是在小样本条件下比端到端训练大模型更稳定。




图 1: 关键模型变体在合并五折测试集上的表现。主模型为影像 MIL 与年龄/性别表格特征等权融合，并采用验证集选择的高敏感度阈值。

2.4 训练与评价

本研究将“非良性/需处理病变”作为筛查任务中的阳性类，因此评价时尤其关注阳性类敏感度，即非良性/需处理病例不被漏诊的比例。主报告指标包括 Accuracy、Balanced Accuracy、Macro-F1、Sensitivity、Specificity、AUROC 和 Average Precision。

由于类别不平衡，Accuracy 不能单独反映模型质量。对于本任务而言，假阴性（非良性/需处理病变被判定为良性神经源性肿瘤）比假阳性更加值得警惕。因此，主模型采用验证集选择的高敏感度工作点，目标是提高阳性类检出率，同时保留一定良性识别能力。

3 结果

3.1 总体性能

表2总结了主要模型及对照实验结果。当前主模型为“ResNet18 2.5D MIL + 年龄/性别等权融合 + 高敏感度阈值”。其合并五折测试结果为 Accuracy 0.821、Balanced Accuracy 0.691、Macro-F1 0.711、Sensitivity 0.927、Specificity 0.455、AUROC 0.670、Average Precision 0.848。

表 2: 主要模型与对照结果

模型	Acc	BAcc	Macro-F1	Sens	Spec	AUROC	AP
Image MIL + 年龄/性别, 旧基线	0.789	0.650	0.664	0.901	0.400	0.698	0.863
年龄/性别 only	0.805	0.661	0.679	0.921	0.400	0.671	0.869
Image MIL + 年龄/性别等权融合, 主模型	0.821	0.691	0.711	0.927	0.455	0.670	0.848
Image-only gated MIL	0.667	0.656	0.610	0.675	0.636	0.643	0.850

混淆矩阵见图2。在 191 例非良性/需处理病变中，177 例被正确判为阳性，14 例被误判为良性神经源性肿瘤；在 55 例良性神经源性肿瘤中，25 例被正确判为阴性，30 例被判为阳性。




图 2: 主模型合并五折测试集混淆矩阵。行表示真实标签，列表示预测标签。

3.2 按原始病理分组的召回表现

进一步按原始病理分组统计召回率，结果见表3。主模型对肉瘤类、PPGL、淋巴瘤和胃肠道间质瘤均保持较高召回率，说明模型在筛查“需处理病变”时有一定积极信号。但良性神经源性肿瘤的特异度只有 0.455，意味着仍有较多良性病例被模型判为需处理。

表 3: 主模型按原始类别统计的召回表现

原始类别	例数	召回率
肉瘤类	103	0.932
PPGL	30	0.933
淋巴瘤	44	0.932
胃肠道间质瘤	14	0.857
良性神经源性肿瘤	55	0.455

3.3 预处理与增强消融

为了验证更复杂预处理是否能提升结果，本研究额外尝试了 body crop、多视角数据增强、不同切片采样策略和不同 CT 窗设置。结果如图3和表4所示。




图 3: 预处理与增强消融实验。更复杂的 body crop、多视角增强或切片/窗宽调整并未稳定优于当前主模型。

表 4: 预处理和增强实验摘要

实验	Acc	BAcc	Macro-F1	Sens	Spec	AUROC
主模型: 96 切片 + 三窗 + 年龄/性别融合	0.821	0.691	0.711	0.927	0.455	0.670
Body crop image-only	0.764	0.576	0.584	0.916	0.236	0.686
多视角增强 + 年龄/性别融合	0.772	0.627	—	0.890	0.364	0.667
高斯采样 64 切片 image-only	0.785	0.628	—	0.911	0.345	0.693
超宽窗 96 切片 image-only	0.752	0.601	—	0.874	0.327	0.699

这些结果提示：当前主要瓶颈不一定是切片数量或窗宽窗位设置本身，而可能来自病例量、标签噪声、影像表型重叠以及缺乏病灶定位。Body crop 虽然可以去掉部分空气背景，但实际裁剪区

域仍接近全腹部，并没有真正定位肿瘤。多视角增强也未改善筛查工作点，反而使假阴性略有增加。因此，在当前阶段保留更简洁的 96 切片三窗输入更合理。

4 讨论

4.1 为什么二分类比多分类更适合当前数据

早期实验尝试过五分类、七分类和 3D 模型，但在当前样本量下，各少数类的稳定评估较困难，且模型容易过拟合。相比之下，“良性神经源性肿瘤 vs 非良性/需处理病变”的二分类任务更贴近当前数据规模，也更符合临床筛查逻辑：我们最担心的不是把良性病例多判为需处理，而是把肉瘤、淋巴瘤、PPGL 或 GIST 误判为普通良性神经源性肿瘤。

因此，主模型优先选择高敏感度阈值。结果中 14 例非良性/需处理病变被误判为良性，这是目前最需要继续分析的错误类型；而 30 例良性神经源性肿瘤被判为需处理，虽然会降低特异度，但在筛查场景下相对可接受。

4.2 年龄和性别特征的意义

年龄、性别等表格特征在本任务中提供了明显增益。需要强调的是，这既可能反映真实流行病学差异，也可能反映当前数据集中的采样偏倚。因此，本研究没有将表格特征解释为病理机制，而是将其作为提高筛查性能的辅助变量。未来若进行外部验证，应单独报告影像 only 模型、表格 only 模型和融合模型，避免把数据集偏倚误认为影像模型能力。

4.3 为什么没有采用分割或 TotalSegmentator

本研究没有使用肿瘤分割，原因有二。第一，当前数据没有医生逐层 ROI 标注，硬做分割式分类会显著增加人工成本。第二，探索性实验显示，通用解剖分割或粗略 body crop 只能提供身体范围或大腹部范围，不能可靠定位腹膜后肿瘤本身。因此，这类方法目前不能替代病灶 ROI。若后续有人工粗框或肿瘤中心点，则更值得尝试的是“粗定位 +MIL”而不是全自动通用器官分割。

4.4 局限性

本研究仍有明显局限：

- 数据量仍偏小，且缺乏独立外部测试集；
- 当前结果来自内部五折交叉验证，不应等同于真实临床泛化性能；
- 没有病灶分割、粗框或医生 ROI，模型可能学习到与肿瘤无关的背景差异；
- 年龄和性别特征可能带来数据集偏倚；
- 良性神经源性肿瘤特异度仍较低，模型会将较多良性病例判为需处理；
- PPGL 被归入“非良性/需处理”是临床任务定义，不是将其简单等同于恶性肿瘤。

5 结论

本研究构建了一个无 ROI 标注条件下的腹膜后肿瘤 CT 二分类筛查基线。基于 96 张轴位切片、三窗输入、ResNet18 切片特征和 2.5D MIL 聚合，并融合年龄/性别信息后，模型在 246 例内部五折交叉验证中实现了较高的非良性/需处理病变敏感度。当前结果说明该路线具备作为初步筛查实验的可行性，但尚不足以支持临床诊断应用。后续工作应优先补充外部验证集、进行病例级错误分析，并在可承受人工成本的前提下探索粗框或中心点辅助定位。

代码与数据说明

项目代码、标签说明和报告文件保存在私有 Git 仓库中。原始 NIfTI、缓存 tensor、ResNet 特征 tensor 和模型权重不纳入 Git 版本控制，以避免隐私和仓库体积问题。当前主线训练入口为二分类影像-表格融合模型；旧的五分类、3D、分割和 41 例小试验分支已从当前工作树移除，仅保留在 Git 历史中可追溯。

参考文献

- [1] He K, Zhang X, Ren S, Sun J. Deep Residual Learning for Image Recognition. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition; 2016.
- [2] Ilse M, Tomczak J, Welling M. Attention-based Deep Multiple Instance Learning. International Conference on Machine Learning; 2018.
- [3] Deng J, Dong W, Socher R, Li L-J, Li K, Fei-Fei L. ImageNet: A Large-Scale Hierarchical Image Database. IEEE Conference on Computer Vision and Pattern Recognition; 2009.