

腹膜后肿瘤 CT 二分类筛查模型技术报告

2026-07-04

项目仓库: `retroperitoneal-tumor-diagnosis`

当前主线任务:

良性神经源性肿瘤 vs 非良性/需处理腹膜后肿瘤

本报告面向研究数学、统计学习和算法的合作者，目标是不阅读代码也能完整理解当前数据如何整理、影像如何预处理、模型如何构造、训练和评价如何进行，以及当前结果应如何解释。

1. 总览

1.1 当前问题不是严格的“良恶性分类”

当前二分类任务的医学语义是筛查式的:

- 阴性类: 良性神经源性肿瘤。
- 阳性类: 非良性或需要进一步处理的腹膜后病变。

这不是严格病理学意义上的 `benign vs malignant`。尤其是 PPGL 并不适合简单称为“恶性”，但它不应与普通良性神经源性肿瘤合并为低风险阴性，因此放入“非良性/需处理”阳性类。

1.2 当前模型路线

当前路线是无 ROI、无分割、无肿瘤中心点的弱监督 `scan-level` 模型:

原始 `NIfTI CT`

- > 统一方向
- > 均匀采样 96 张 `axial slices`
- > 三窗 `CT` 通道

- > `resize` 到 224 x 224
- > ImageNet 预训练 ResNet18 提取每张 slice 的 512 维特征
- > 多实例学习 MIL 聚合 96 个 slice features
- > 可选融合年龄/性别
- > 输出病例级二分类概率

核心设计取舍：

- 不做肿瘤分割，因为没有可靠医生 ROI 标注。
- 不做 TotalSeg/器官分割作为核心输入，因为器官先验不能直接定位腹膜后肿瘤。
- 不直接训练大型 3D CNN，因为当前数据量有限，且全腹部输入里肿瘤占比小。
- 使用 2.5D slice feature + MIL，减少训练成本，也便于在 GPU 上快速迭代。

2. 仓库结构与文件职责

当前保留的是二分类主线，旧的五分类、3D baseline、TotalSeg/ULS23 和 41 例小试验已从当前工作树移除。

```
data/
  labels/
    labels_5class.csv
    binary_label_mapping.json
    dataset_summary.json
    binary_fold_counts.csv
    splits/fold_0..fold_4/{train,val,test}.csv

  cache_96slice/
    README.md
    dataset_summary.json
    tensors_sha256.csv
    tensors/*.pt                # 被 .gitignore 忽略

  features_cache_96slice_resnet18/
    README.md
    dataset_summary.json
    features_sha256.csv
    features/*.pt                # 被 .gitignore 忽略
```

```

data_private/
  standard/
    all.csv
    labels.csv
    metadata.csv
    checksums_sha256.csv
    *.nii.gz                # 被 .gitignore 忽略
  audit/
    header_audit.csv
    linkage_audit_with_phi.csv

scripts/
  02_build_96slice_cache.py
  03_extract_slice_features.py
  20_train_binary_feature_fusion.py

reports/
  binary_benign_malignant_trial_report.md
  technical_report_binary_nonbenign.md
assets/
  binary_trial_metrics.png
  binary_trial_confusion.png

envs/
  ENVIRONMENT.md
  environment-cu118.yml
  requirements-cu118.txt

```

隐私策略：

- GitHub 只保留脱敏标签、fold split、缓存摘要和代码。
 - 原始 NIfTI、tensor cache、ResNet feature tensor、模型权重、私有 Excel、盐值和 PHI linkage audit 不进入 Git。
 - data_private/ 仅本地保留。
-

3. 数据定义

3.1 原始五类标签

当前监督数据来自 246 例 CT。五类标签分布如下：

原始 5 类标签	例数
肉瘤类	103
良性神经源性肿瘤	55
淋巴瘤	44
PPGL	30
胃肠道间质瘤	14

另有部分病例在数据清理中排除：

- 坏数据组：G0122, G0137, G0369
- 无监督标签组：G0180, G0224, G0296

3.2 二分类映射

设五类标签为 c_i ，二分类标签为 $y_i \in \{0, 1\}$ 。

映射规则：

二分类 id	二分类名称	例数
0	<code>benign_neurogenic</code>	55
1	<code>nonbenign_actionable</code>	191

来源标签映射：

- `benign_neurogenic`：良性神经源性肿瘤。
- `nonbenign_actionable`：肉瘤类、淋巴瘤、PPGL、胃肠道间质瘤。

数学表示：

$$y_i = \begin{cases} 0, & c_i = \text{良性神经源性肿瘤}, \\ 1, & c_i \in \{\text{肉瘤类, 淋巴瘤, PPGL, 胃肠道间质瘤}\}. \end{cases}$$

阳性类不是“恶性”的字面等价，而是“非良性/需处理”的筛查定义。

4. 数据划分

4.1 划分原则

使用患者级 5-fold cross-validation。划分依据是脱敏后的 `patient_uid_hash`，而不是 `slice`、`series` 或文件路径，因此同一患者不会同时出现在训练集和测试集。

划分方法：

`StratifiedGroupKFold`

```
stratification target: binary label
group key: salted patient_uid_hash
n_splits: 5
```

每一折包含 train、validation 和 test：

- train：用于参数更新；
- validation：用于选择最佳 epoch 和阈值；
- test：只用于最终该折测试；
- pooled test：合并 5 折 test 预测，每个病例只出现一次，因此总数为 246。

4.2 每折数量

表中括号格式为 总例数（良性/非良性）。

Fold	Train	Val	Test
0	147 (34/113)	50 (11/39)	49 (10/39)
1	147 (34/113)	49 (10/39)	50 (11/39)
2	147 (33/114)	50 (12/38)	49 (10/39)
3	148 (31/117)	48 (12/36)	50 (12/38)
4	149 (33/116)	49 (10/39)	48 (12/36)

4.3 为什么 pooled test 有 246 例

单折 test 只有约 48 到 50 例。但 5-fold cross-validation 中，每个病例都会在某一折作为 test 出现一次。把 5 个 test fold 合并后：

$$49 + 50 + 49 + 50 + 48 = 246.$$

因此 pooled confusion matrix 的四格之和是 246。

5. 影像预处理

预处理由 `scripts/02_build_96slice_cache.py` 完成。

5.1 输入

输入为本地私有目录中的 NIfTI CT:

`data_private/standard/*.nii.gz`

原始 NIfTI 不进入 Git。

5.2 方向统一

使用 `nibabel` 读取 NIfTI, 并调用:

`nib.as_closest_canonical(raw_img)`

目的:

- 统一数据方向;
- 降低不同 DICOM/NIfTI 转换方向差异带来的 slice 顺序和轴向不一致;
- 保留 header audit 以便后续检查原始方向和 canonical 方向。

5.3 均匀采样 96 张 axial slices

设 canonical CT volume 为:

$$V \in \mathbb{R}^{H \times W \times Z}.$$

沿 axial 方向均匀采样 96 个 index:

$$z_k = \text{round} \left(\frac{k(Z-1)}{95} \right), \quad k = 0, 1, \dots, 95.$$

得到 slice bag:

$$S_i = \{V[:, :, z_0], V[:, :, z_1], \dots, V[:, :, z_{95}]\}.$$

注意:

- 当前是全图均匀采样，不做肿瘤区域裁剪；
- 如果某些病例 slice 数小于 96，均匀采样的 round 可能重复某些 z-index，这是固定长度输入的自然结果；
- 这种做法保留了 scan-level 弱监督设定，但会引入大量无关背景。

5.4 三通道 CT 窗

每张原始 CT slice 是 HU 值图像。为了使用 ImageNet 预训练 ResNet18，构造 3 通道输入，每个通道是一个窗：

通道	窗	目的
1	[-160, 240]	soft tissue window
2	[-200, 100]	fat-sensitive window
3	[-200, 400]	wide abdomen window

对任一像素 HU 值 x ，给定窗 $[a, b]$ ，通道值为：

$$g_{a,b}(x) = \frac{\min(\max(x, a), b) - a}{b - a}.$$

因此 $g_{a,b}(x) \in [0, 1]$ 。

三通道 slice 表示为：

$$X_k = [g_{-160,240}(S_k), g_{-200,100}(S_k), g_{-200,400}(S_k)].$$

5.5 Resize 与存储

每张 slice resize 到 224 x 224:

[96, 3, H, W] -> [96, 3, 224, 224]

插值方法:

```
torch.nn.functional.interpolate(..., mode="bilinear", align_corners=False)
```

缓存格式:

shape: [96, 3, 224, 224]

dtype: uint8

range: 0..255

即窗口归一化后乘 255 保存, 以减少存储占用。

缓存摘要:

```
{
  "name": "cache_96slice",
  "num_cases": 249,
  "tensor_shape": [96, 3, 224, 224],
  "tensor_dtype": "uint8"
}
```

其中 249 是影像缓存数, 最终监督训练使用其中 246 例有标签病例。

6. ResNet18 slice 特征提取

特征提取由 scripts/03_extract_slice_features.py 完成。

6.1 输入归一化

读取缓存 tensor 后:

$$X = \frac{\text{uint8}(X)}{255}.$$

再使用 ImageNet mean/std 标准化:

$$\tilde{X}_c = \frac{X_c - \mu_c}{\sigma_c}.$$

其中:

```
mean = [0.485, 0.456, 0.406]
std  = [0.229, 0.224, 0.225]
```

虽然 CT 三窗并不是自然图像 RGB，但这个标准化与 ImageNet 预训练 ResNet18 输入约定一致。

6.2 ResNet18 backbone

使用 `torchvision.models.resnet18(weights=ResNet18_Weights.DEFAULT)`。

去掉最后分类层:

```
model.fc = torch.nn.Identity()
```

每张 slice 得到一个 512 维特征:

$$f_{ik} = \phi(X_{ik}) \in \mathbb{R}^{512}.$$

每个病例得到:

$$F_i = \begin{bmatrix} f_{i1} \\ f_{i2} \\ \vdots \\ f_{i96} \end{bmatrix} \in \mathbb{R}^{96 \times 512}.$$

缓存格式:

```
{
  "name": "features_cache_96slice_resnet18",
  "backbone": "resnet18",
  "pretrained": "ImageNet",
  "num_cases": 246,
  "feature_shape": [96, 512],
  "feature_dtype": "float16"
}
```

特征提取阶段 ResNet18 冻结，仅作为 feature extractor。

7. 病例级模型

病例级训练由 `scripts/20_train_binary_feature_fusion.py` 完成。

7.1 输入变量

对第 i 个病例：

- 影像特征： $F_i \in \mathbb{R}^{96 \times 512}$ ；
- 年龄： $a_i \in \mathbb{R}$ ；
- 性别： $s_i \in \{\text{M}, \text{F}\}$ ，其中 M/F 分别对应原始表格里的男/女；
- 二分类标签： $y_i \in \{0, 1\}$ ；
- 五类标签： $c_i \in \{0, 1, 2, 3, 4\}$ ，仅用于 subtype audit 或可选 auxiliary loss。

年龄标准化：

$$\hat{a}_i = \frac{a_i - \mu_{\text{train}}}{\sigma_{\text{train}}}.$$

性别 one-hot。为避免数学公式中的中文字体问题，这里用 M/F 表示男/女：

$$\text{sex}_i = [\mathbb{1}(s_i = \text{M}), \mathbb{1}(s_i = \text{F})].$$

表格输入：

$$t_i = [\hat{a}_i, \text{sex}_{i,M}, \text{sex}_{i,F}] \in \mathbb{R}^3.$$

年龄均值和标准差只在当前 fold 的 training set 上估计。

7.2 Feature normalization

默认对 slice feature 做 LayerNorm：

$$\bar{f}_{ik} = \text{LayerNorm}(f_{ik}).$$

LayerNorm 的目的是稳定不同病例和不同 slice 之间的特征尺度。

7.3 z-position embedding

部分 MIL head 使用 z-position embedding。对第 k 张 slice:

$$r_k = \frac{k}{95}, \quad r_k \in [0, 1].$$

通过一个两层 MLP:

$$e_k = W_2 \text{ReLU}(W_1 r_k + b_1) + b_2,$$

其中 $e_k \in \mathbb{R}^{512}$ 。

加入位置后的特征:

$$h_{ik} = \bar{f}_{ik} + e_k.$$

直觉上, 腹部 CT 中 slice 的 cranio-caudal 位置有信息, z-position embedding 让模型知道某个 slice 大致来自体轴哪个位置。

7.4 MIL 聚合方式

7.4.1 Mean/Max pooling 最基础的聚合:

$$m_i = \frac{1}{96} \sum_{k=1}^{96} h_{ik},$$

$$u_i = \max_{k=1, \dots, 96} h_{ik},$$

最终图像表示:

$$z_i^{\text{img}} = [m_i, u_i] \in \mathbb{R}^{1024}.$$

这个 head 简单、稳定, 是当前最可靠的影像 baseline。

7.4.2 Top-k MIL Top-k head 先为每个 slice 学习一个标量 score:

$$q_{ik} = w_2^\top \text{ReLU}(W_1 h_{ik} + b_1) + b_2.$$

选出分数最高的 $K = 8$ 个 slice:

$$\mathcal{K}_i = \text{TopK}(\{q_{ik}\}_{k=1}^{96}, K).$$

对这些 slice 的投影特征取平均:

$$z_i^{\text{img}} = \frac{1}{K} \sum_{k \in \mathcal{K}_i} \text{ReLU}(W_p h_{ik} + b_p).$$

这个设计试图模拟“只有少数层面真正包含病灶”的弱监督假设。

7.4.3 Gated attention MIL Gated attention MIL 使用:

$$a_{ik} = w^\top [\tanh(V h_{ik}) \odot \sigma(U h_{ik})].$$

将 score softmax 为注意力权重:

$$\alpha_{ik} = \frac{\exp(a_{ik})}{\sum_{\ell=1}^{96} \exp(a_{i\ell})}.$$

图像表示:

$$z_i^{\text{img}} = \sum_{k=1}^{96} \alpha_{ik} h_{ik}.$$

其中 α_{ik} 也可以导出为模型“更关注哪些 slice”的粗略解释, 但它不是病灶定位结果。

7.5 年龄/性别分支

当启用 FUSION=1 或 POOLING=metadata_only 时, 表格变量经过小型 MLP:

$$z_i^{\text{tab}} = \text{MLP}(t_i) \in \mathbb{R}^{16}.$$

当前 MLP:

```
Linear(3, 16)
ReLU
Dropout(0.1)
Linear(16, 16)
ReLU
```

7.6 图像与表格融合

若使用图像 + 表格融合:

$$z_i = [z_i^{\text{img}}, z_i^{\text{tab}}].$$

若使用 image-only:

$$z_i = z_i^{\text{img}}.$$

若使用 metadata-only:

$$z_i = z_i^{\text{tab}}.$$

7.7 分类头

分类头输出二分类 logits:

$$\ell_i = Wz_i + b \in \mathbb{R}^2.$$

阳性类概率:

$$p_i = P(y_i = 1 \mid F_i, t_i) = \frac{\exp(\ell_{i,1})}{\exp(\ell_{i,0}) + \exp(\ell_{i,1})}.$$

对于更复杂的 head, 分类器前还有:

```
LayerNorm
Dropout
```

Linear(dim, 256)

ReLU

Dropout

Linear(256, 2)

8. 训练目标与采样策略

8.1 Cross entropy

基础二分类损失为交叉熵：

$$\mathcal{L}_{CE} = - \sum_{i=1}^B \log P(y_i | F_i, t_i).$$

8.2 Class-weighted cross entropy

由于阴性 55 例、阳性 191 例，类别不平衡明显。class weight 在训练 fold 内计算：

$$w_c = \frac{N}{2N_c},$$

其中 N_c 是 class c 的训练样本数。

加权 CE：

$$\mathcal{L}_{WCE} = - \sum_{i=1}^B w_{y_i} \log P(y_i | F_i, t_i).$$

8.3 Focal loss

脚本还支持 focal loss：

$$\mathcal{L}_{focal} = -(1 - p_t)^\gamma \log(p_t),$$

其中 p_t 是真实类别概率，默认 $\gamma = 2$ 。

8.4 Sampler

训练脚本支持三种采样：

Sampler	权重逻辑	用途
natural	原始分布	baseline
balanced	二分类类别反频率	平衡良性和非良性
subtype_balanced	原五类标签反频率	避免 GIST、PPGL 等少数 subtype 被忽略

subtype_balanced 中，样本权重为：

$$\omega_i = \frac{1}{N_{c_i}},$$

其中 c_i 是原始五类标签。

9. 阈值选择

模型输出的是阳性概率 p_i 。给定阈值 τ ：

$$\hat{y}_i = \begin{cases} 1, & p_i \geq \tau, \\ 0, & p_i < \tau. \end{cases}$$

支持四种阈值模式：

模式	阈值定义
fixed_05	$\tau = 0.5$
youden	最大化 sensitivity + specificity - 1
sens90	在 validation sensitivity 达到 0.90 的候选阈值中最大化 specificity
sens85	在 validation sensitivity 达到 0.85 的候选阈值中最大化 specificity

重要原则：

- 阈值只在 validation set 上选；
- test set 不参与阈值选择；
- pooled test 指标由各 fold 自己的 validation-selected threshold 产生。

这避免了直接在 test set 上调阈值造成的乐观偏差。

10. 评价指标

混淆矩阵使用：

[[TN, FP],
[FN, TP]]

其中阳性类为非良性/需处理。

核心指标：

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}.$$

$$\text{Sensitivity} = \frac{TP}{TP + FN}.$$

$$\text{Specificity} = \frac{TN}{TN + FP}.$$

$$\text{BalancedAccuracy} = \frac{1}{2} (\text{Sensitivity} + \text{Specificity}).$$

Macro-F1 是两个类别 F1 的算术平均。Weighted-F1 按类别样本数加权。

同时报告：

- AUROC：阈值无关的 ROC 曲线下面积；
- Average Precision：precision-recall 曲线下面积；
- PPV 和 NPV；
- subtype recall：按原五类标签分别计算二分类是否正确。

对于本任务，最临床相关的错误是：

FN = 非良性/需处理病例被预测为良性神经源性肿瘤

因此 sensitivity 是筛查优先级较高的指标，但 specificity 也需要持续提高。

11. 实验设置

11.1 当前主要模型族

本轮比较了：

设置	图像输入	表格输入	聚合	说明
image-only mean/max	是	否	mean/max	基础影像模型
metadata-only	否	是	无	年龄/性别对照
ResNet18 + metadata	是	是	mean/max	旧主线
gated MIL fusion	是	是	gated attention + z-position	更复杂 MIL
late fusion ensemble	是	是	概率平均	融合不同模型输出

11.2 默认训练超参数

参数	值
Epochs	60 到 80，视实验而定
Batch size	16
Optimizer	AdamW
Learning rate	0.001
Weight decay	0.0001
Dropout	0.15 到 0.20
Device priority	CUDA > MPS > CPU
Seed	20260704

11.3 运行输出

每个 fold 的训练输出保存在 `runs/<RUN_NAME>/`：

```
model_best.pt
model_last.pt
train_log.csv
val_predictions.csv
test_predictions.csv
test_metrics.json
test_metrics_fixed05.json
test_subtype_metrics.csv
thresholds.json
config.json
```

这些训练输出和模型权重不进入 Git。

12. 当前结果

12.1 Pooled 5-fold test 结果

下表为 5-fold pooled test 指标。每个病例在 pooled test 中出现一次，总数 246。

实验编号：

- S0: 旧主线, ResNet18 mean/max + 年龄/性别。
- S1: 年龄/性别 only, validation sens85 阈值。
- S2: 图像 only mean/max, 固定 0.5 阈值。
- S3: 图像 only gated attention, 固定 0.5 阈值。
- S4: 推荐筛查点, metadata + gated MIL fusion, validation sens85 阈值。
- S5: 推荐平衡点, metadata + image-only mean/max late fusion, validation sens85 阈值。
- S6: 更高 specificity 点, metadata + baseline fusion, 固定 0.5 阈值。

主要分类指标:

ID	Acc	BAcc	Macro-F1	Sens	Spec
S0	0.789	0.650	0.664	0.901	0.400
S1	0.805	0.661	0.679	0.921	0.400
S2	0.732	0.614	0.614	0.827	0.400
S3	0.667	0.656	0.610	0.675	0.636
S4	0.813	0.679	0.698	0.921	0.436
S5	0.805	0.680	0.694	0.906	0.455
S6	0.785	0.686	0.688	0.864	0.509

概率排序和错误类型:

ID	AUROC	AP	Confusion Matrix
S0	0.698	0.863	[[22,33],[19,172]]
S1	0.671	0.869	[[22,33],[15,176]]
S2	0.666	0.869	[[22,33],[33,158]]
S3	0.643	0.850	[[35,20],[62,129]]
S4	0.642	0.833	[[24,31],[15,176]]
S5	0.712	0.871	[[25,30],[18,173]]
S6	0.698	0.863	[[28,27],[26,165]]

12.2 推荐筛查点

若目标是尽量减少非良性/需处理病例漏判，当前推荐主结果是：

```
metadata + gated MIL fusion, validation sens85 threshold
Accuracy:          0.813
Balanced Accuracy: 0.679
Macro-F1:          0.698
Sensitivity:        0.921
Specificity:        0.436
Confusion Matrix:  [[24,31],[15,176]]
```

与旧主线相比:




图 1: 二分类指标对比




图 2: 推荐筛查点混淆矩阵

指标	旧主线	当前推荐筛查点
False negative	19	15
False positive	33	31
Accuracy	0.789	0.813
Balanced Acc	0.650	0.679
Macro-F1	0.664	0.698
Sensitivity	0.901	0.921
Specificity	0.400	0.436

这说明当前改进不是简单地“把更多病例判为阳性”：false negative 和 false positive 都比旧主线略少。

12.3 推荐平衡点

如果更强调影像模型贡献和概率排序能力，可考虑：

`metadata + image-only mean/max late fusion, validation sens85 threshold`

Accuracy: 0.805

Balanced Accuracy: 0.680

Macro-F1: 0.694

Sensitivity: 0.906

Specificity: 0.455

AUROC: 0.712

Confusion Matrix: [[25,30],[18,173]]

这个设置的 AUROC 和 specificity 更好，且 sensitivity 仍超过 0.90。它比 `metadata + gated MIL fusion` 更像一个可以继续发展的图像-表格融合基线。

12.4 亚型表现

推荐筛查点 `metadata + gated MIL fusion` 的原五类 subtype recall:

原 5 类	n	二分类目标	Recall
肉瘤类	103	非良性/需处理	0.942
良性神经源性肿瘤	55	良性神经源性肿瘤	0.436
PPGL	30	非良性/需处理	0.867
淋巴瘤	44	非良性/需处理	0.909
胃肠道间质瘤	14	非良性/需处理	0.929

主要短板：

- 良性神经源性肿瘤 55 例中，只有 24 例被正确判为良性；
 - 31 例良性神经源性肿瘤被判为非良性/需处理；
 - 因此 specificity 仍然偏低。
-

13. 结果解释

13.1 二分类比五分类更适合当前阶段

五分类要求模型区分肉瘤、淋巴瘤、PPGL、GIST 和良性神经源性肿瘤。当前数据量和无 ROI 条件下，这一任务过难，且各亚型样本数不平衡明显。

二分类将目标改成“良性神经源性肿瘤 vs 非良性/需处理”，更符合当前数据规模和临床筛查语境，因此结果明显更可用。

13.2 年龄/性别是强对照，不能忽略

metadata-only 的表现已经很强：

Accuracy 0.805

Sensitivity 0.921

Specificity 0.400

这说明年龄和性别中包含明显区分信息。报告模型时必须诚实说明：

- 当前性能不是纯 CT 影像贡献；
- 年龄/性别可能携带疾病分布差异；
- 未来若要强调影像算法贡献，需要保留 metadata-only 作为必要对照。

13.3 影像模型有贡献，但还不稳定

image-only mean/max 模型：

Accuracy 0.732

Sensitivity 0.827

Specificity 0.400

image-only gated attention 固定阈值：

Accuracy 0.667

Sensitivity 0.675

Specificity 0.636

说明影像信号存在，但当前全图无 ROI 模式下，模型容易在 sensitivity 和 specificity 之间摇摆。

13.4 当前最大瓶颈不是 backbone 太小

从实验看，单纯更换更复杂 MIL head 并没有稳定解决问题。原因可能是：

- 肿瘤只占全腹部 CT 的一部分；
- 96 张均匀 slice 中，很多 slice 与病灶无关；
- 没有 lesion crop 时，模型需要同时完成定位和分类；
- 样本量对复杂 head 仍偏小。

因此下一步最可能有效的不是直接堆更大模型，而是加入低成本肿瘤中心点、粗框或 lesion crop。

14. 复现实验命令

以下命令假设数据缓存和特征缓存已经存在。

14.1 构建 96-slice cache

```
python scripts/02_build_96slice_cache.py
```

输出：

```
data/cache_96slice/tensors/*.pt
```

```
data/cache_96slice/tensors_sha256.csv
```

```
data/cache_96slice/dataset_summary.json
```

```
data_private/audit/header_audit.csv
```

14.2 提取 ResNet18 slice features

```
python scripts/03_extract_slice_features.py
```

输出：

```
data/features_cache_96slice_resnet18/features/*.pt
data/features_cache_96slice_resnet18/features_sha256.csv
data/features_cache_96slice_resnet18/dataset_summary.json
```

14.3 训练单折

基础 mean/max + 年龄/性别:

```
FOLD=0 \
FUSION=1 \
POOLING=meanmax \
SAMPLER=natural \
LOSS=weighted_ce \
THRESHOLD_MODE=fixed_05 \
RUN_NAME=binary_fold0_meanmax_fusion \
python scripts/20_train_binary_feature_fusion.py
```

Gated MIL + 年龄/性别 + balanced sampler:

```
FOLD=0 \
FUSION=1 \
POOLING=gated_attention_zpos \
SAMPLER=balanced \
LOSS=ce \
THRESHOLD_MODE=youden \
SELECT_METRIC=youden \
EPOCHS=80 \
RUN_NAME=binary_fold0_gated_fusion_balanced \
python scripts/20_train_binary_feature_fusion.py
```

Metadata-only 对照:

```
FOLD=0 \
FUSION=1 \
POOLING=metadata_only \
SAMPLER=subtype_balanced \
LOSS=ce \
THRESHOLD_MODE=youden \
RUN_NAME=binary_fold0_metadata_only \
python scripts/20_train_binary_feature_fusion.py
```


14.4 训练 5 折

```
for f in 0 1 2 3 4; do
  FOLD=$f \
  FUSION=1 \
  POOLING=meanmax \
  SAMPLER=natural \
  LOSS=weighted_ce \
  RUN_NAME=binary_fold${f}_meanmax_fusion \
  python scripts/20_train_binary_feature_fusion.py
done
```

15. 当前结论

当前项目已经从“多分类复刻式尝试”收敛为一个更清晰、能解释、能复现的二分类筛查任务：

良性神经源性肿瘤

vs

非良性/需处理腹膜后肿瘤

当前推荐主结果：

```
metadata + gated MIL fusion
Accuracy 0.813
Balanced Accuracy 0.679
Macro-F1 0.698
Sensitivity 0.921
Specificity 0.436
Confusion Matrix [[24,31],[15,176]]
```

这个结果适合作为 exploratory screening baseline。它说明模型能够较积极地识别非良性/需处理病例，但仍不能作为临床诊断模型。

最重要的后续方向：

1. 保留 metadata-only 对照，防止误把年龄/性别贡献当成影像贡献。
2. 继续报告 balanced accuracy、sensitivity、specificity，而不是只报 accuracy。
3. 若要提高 specificity，应优先考虑低成本 lesion crop，而不是盲目堆更大网络。
4. 在更多数据补齐后，再重复当前 5-fold pipeline，并比较当前结果是否稳定。

16. 附录：关键文件对照

文件	作用
scripts/02_build_96slice_cache.py	从 NIfTI 生成 96-slice 三窗 tensor
scripts/03_extract_slice_features.py	用 ImageNet ResNet18 提取每张 slice 的 512 维特征
scripts/20_train_binary_feature_fusion.py	训练二分类 MIL/fusion 模型
data/labels/labels_5class.csv	脱敏病例标签表
data/labels/binary_label_mapping.json	二分类标签定义
data/labels/splits/fold_*/*.csv	患者级 5 折 train/val/test
data/cache_96slice/dataset_summary.json	96-slice cache 摘要
data/features_cache_96slice_resnet18/dataset_summary.json	ResNet18 feature cache 摘要
reports/binary_benign_malignant_trial_report.pdf	简版二分类实验报告
reports/technical_report_binary_nonbenign.mdoc	本技术报告